

Projet Deep Learning - Système d'aide au tri radiologique

1. Contexte général

Comment concevoir un système d'aide au tri radiologique capable de prédire des pathologies thoraciques à partir de radiographies, d'identifier des cas atypiques ou hors distribution, d'exploiter le contexte textuel lorsque de vrais comptes-rendus sont disponibles, et de rendre ce système testable via un démonstrateur applicatif ?

Le projet ne se limite pas à une tâche de classification. Il combine **modélisation supervisée sur images, détection d'anomalies, multimodalité image + texte ou image + métadonnées selon les données accessibles, suivi expérimental rigoureux** et **mise à disposition via une interface applicative**.

2. Objectifs pédagogiques

1. Mettre en œuvre des architectures profondes de vision : CNN simple, transfer learning et Vision Transformer ou modèle hybride.
2. Comparer des modèles sur un problème de classification multi-label médical.
3. Construire une brique de détection d'anomalies par AE ou VAE.
4. Exploiter une modalité textuelle ou tabulaire complémentaire quand elle est disponible.
5. Evaluer rigoureusement les modèles avec des métriques adaptées aux classes déséquilibrées.
6. Tracer les expériences avec Mallow et exposer un modèle dans un démonstrateur.

3. Jeux de données recommandés

3.1 Dataset principal : ChestMNIST / ChestMNIST+

Le dataset principal recommande est **ChestMNIST / ChestMNIST+**, sous-ensemble de [MedMNIST](#). Il contient des **radiographies thoraciques** et propose une tâche de classification multilabel sur 14 pathologies. MedMNIST+ propose plusieurs résolutions, notamment 64, 128 et 224, ce qui permet d'adapter la charge de calcul au matériel disponible.

Ce dataset est obligatoire pour la partie classification supervisée image. Les étudiants doivent traiter le problème comme une classification multi-label, avec une probabilité

par pathologie. Une activation sigmoïde par classe et une fonction de perte de type binary cross-entropy sont attendues.

3.2 Dataset secondaire optionnel : NIH ChestX-ray14

[NIH ChestX-ray14](#) peut être utilisé comme dataset secondaire pour travailler sur des **radiographies plus réalistes**, des labels de pathologies et des métadonnées. Il ne doit pas être présenté comme source principale de comptes-rendus textuels complets : les rapports ont servi à générer les labels, mais les textes radiologiques exploitables ne sont pas fournis de manière adéquate pour une vraie multimodalité image + compte-rendu.

Utilisation recommandée : classification multi-label image, comparaison avec ChestMNIST+, analyse de métadonnées, ou multimodalité faible image + métadonnées tabulaires.

Utilisation déconseillée : modèle texte seul ou image + compte-rendu complet.

3.3 Dataset multimodal recommande : OpenI ou MIMICCCXR

Pour la composante multimodale image + texte, vous devez utiliser un dataset qui fournit des radiographies associées à des comptes-rendus radiologiques.

- **Option recommandée pour faisabilité** : [OpenI](#). Dataset plus petit, accessible, adapté à une preuve de concept image + rapport.

- **Option avancée** : [MIMIC-CXR](#). Dataset plus riche et plus réaliste, mais avec contraintes d'accès et de gestion plus fortes.

4. Contraintes obligatoires

4.1 Classification supervisée sur images

Résoudre une tâche de classification multi-label de pathologies thoraciques à partir de radiographies et comparer au moins **trois architectures profondes** :

- Un **CNN** entraîne depuis zéro.
- Un **CNN pré-entraîne** avec **transfer learning** : ResNet, DenseNet, EfficientNet ou équivalent.
- Un **Vision Transformer (ViT)** ou un modèle hybride CNN/Transformer.

Chaque modèle doit être justifié par rapport au cours : couches de convolution, pooling, fonctions d'activation, normalisation, connexion résiduelle, attention, patches visuels et intérêt ou non du ViT, etc.

4.2 Détection d'anomalies par AE ou VAE

Implémenter **au moins un** modèle parmi : **autoencodeur convolutionnel (AE)** ou **Variational Autoencoder (VAE)**. Cette composante doit produire un score d'anomalie fonde sur l'erreur de reconstruction, l'espace latent ou une combinaison justifiée.

Préciser le protocole : données utilisées pour l'apprentissage, choix du seuil, exemples d'images fortement atypiques, limites d'interprétation clinique.

4.3 Composante multimodale

Intégrer une **preuve de concept multimodale** utilisant un dataset avec **image + texte**. Comparer au minimum :

- Un modèle **image seule**,
- Un modèle **texte seul**,
- Un modèle **multimodal fusionné**.

La stratégie de fusion doit être justifiée : **fusion précoce**, **fusion tardive** ou **fusion intermédiaire**. Une discussion sur l'alignement image-texte et les modalités manquantes est attendue.

4.4 Tracking expérimental avec MLflow

Toutes les expériences doivent être tracées avec **MLflow**. Pour chaque run : **hyperparamètres**, **métriques**, **artefacts**, figures, courbes, matrices, sorties de reconstruction, **meilleur modèle** et configuration d'entraînement doivent être enregistrés.

4.5 Démonstrateur applicatif

Livrer un prototype testable avec **Streamlit**, **Gradio** ou **Flask**. Le démonstrateur doit permettre de charger une radiographie, afficher les **prédictions supervisées**, afficher un **score d'anomalie**, et si la brique multimodale est implémentée, traiter un **compte-rendu** ou des métadonnées complémentaires.

4.6 Pipeline propre et reproductible

- Séparation claire **train / validation / test**+ méthode de validation rigoureuse.
- Absence de **fuite de données**, notamment par patient si les identifiants sont disponibles.
- **Seed fixe** ou stratégie de reproductibilité documentée.
- Sauvegarde du **meilleur modèle**.
- Cohérence stricte entre modèle entraîne, run MLflow retenu et modèle expose dans le démonstrateur.

5. Structure attendue du rapport

Le rapport final doit contenir les sections suivantes, dans cet ordre.

- **Problème** : contexte, objectif métier, problématique IA, intérêt du tri radiologique.
- **Données** : datasets, sources, structure, limites, contraintes d'accès, justification du choix multimodal.
- **Analyse exploratoire** : distribution des labels, déséquilibre, exemples visuels, co-occurrences, premiers constats texte ou métadonnées.
- **Préparation** : preprocessing images, normalisation, augmentation, labels multilabel, texte ou métadonnées, déséquilibre, stratégie antifuite.
- **Modélisation supervisée** : trois architectures profondes et justification.
- **Détection d'anomalies** : AE/VAE, fonction de perte, protocole, score, analyse des cas atypiques.
- **Modélisation multimodale** : représentations, fusion, comparaison image seule / texte seul / multimodal ou image + métadonnées.
- **Evaluation** : métriques globales et par classe, courbes, matrices, analyse critique.
- **Tracking MLflow** : organisation des runs, paramètres testes, meilleur run, preuve du modèle déployé.
- **Démonstrateur** : architecture, fonctionnalités, limites, interaction utilisateur.
- **Analyse critique** : robustesse, généralisation, erreurs fréquentes, cout calculatoire, apport de la multimodalité et de l'AE/VAE.
- **Conclusion et perspectives**.

6. Exigences techniques minimales

- Frameworks autorisés : PyTorch, TensorFlow/Keras, scikit-learn pour baselines et EDA, bibliothèques Python de visualisation.
- MLflow obligatoire pour le suivi expérimental.
- Streamlit, Gradio ou Flask pour le démonstrateur.
- Documentation de la configuration matérielle, des temps d'entraînement et des contraintes de calcul.
- Documentation des choix de régularisation et optimisation : augmentation, early stopping, dropout, weight decay, scheduler, Adam/AdamW, batch size.

7. Livrables attendus

1. Rapport final structuré, clair et argumenté, respectant les sections imposées.
2. Dépôt de code contenant entraînement supervisé, AE/VAE, multimodalité, démonstrateur, scripts MLflow et README clair.
3. Démonstrateur fonctionnel exécutable localement ou déployé.
4. Export ou capture MLflow montrant les runs et le meilleur modèle retenu.